

Introdução aos Sistemas Distribuídos

Objetivos de Projeto de Sistemas Distribuídos

Parte III - Teoria de Filas

Prof. Carlos A. Astudillo

✉ castudillo@unicamp.br

📖 Sistemas Distribuídos (MC714A)

📅 2º Semestre 2026

Agenda

- Teoria das Filas (tudo o que é necessário para o Trabalho 1)
 - ▶ Vocabulário e métricas: λ , μ , X , U , $E[R]$
 - ▶ Lei de Little
 - ▶ Decomposição de Poisson e a fila M/M/1
 - ▶ Do balanceador de carga ao modelo analítico
 - ▶ Estabilidade e regime transiente

Teoria de Filas

Tudo o que é necessário para resolver o **Trabalho 1**

Os frames marcados com [T1: item x] indicam a qual item do enunciado o conteúdo se aplica.

Teoria de Filas

Por que precisamos disto?

- Ferramenta para analisar formalmente a **escalabilidade de tamanho**: quanto o desempenho degrada quando a carga aumenta?
- A intuição do dia a dia já traz os conceitos: *chegadas, fila, atendimento, quanto tempo eu esperei.*




O sistema do Trabalho 1

Tudo nesta aula serve para modelar esta figura

- Chegadas de **Poisson** de taxa λ .
- Um **balanceador** que escolhe um dos 3 servidores.
- **3 servidores homogêneos**, cada um com **1 thread** e **fila FCFS ilimitada**.
- Tempo de serviço **exponencial** de média $1/\mu$, com $\mu = 1$ req/ u.t..

Três políticas: **aleatória**, **round-robin**, **fila mais curta**.



Teoria de Filas

Vocabulário: as duas taxas

Taxa média de chegada λ

Taxa média na qual novas tarefas chegam ao sistema. Ex.: $\lambda = 3$ req/s significa que, *em média*, chegam 3 requisições por segundo — em alguns segundos chegam mais, em outros menos.

Tempo entre chegadas I

Assume-se que os tempos entre chegadas são i.i.d., com $E[I] = 1/\lambda$. No Trabalho 1: $I \sim \text{Exponencial}(\lambda)$.

Tamanho / requisito de serviço S , e taxa de serviço μ

S é o tempo que a tarefa levaria neste servidor se *não houvesse fila*. $E[S]$ é o tempo médio de serviço e $\mu = 1/E[S]$ é a taxa média de serviço. No Trabalho 1: $S \sim \text{Exponencial}(\mu)$, $\mu = 1$, logo $E[S] = 1$ u.t..

Teoria de Filas

Cuidado: μ é uma *taxa*, $E[S]$ é um *tempo*

- A taxa média de chegada de tarefas é 3 tarefas por segundo.
- As tarefas têm requisitos diferentes, mas em média cada uma precisa de 2000 ciclos.
- A velocidade da CPU é 8000 ciclos por segundo.
- Ou seja: chegam 6000 ciclos de trabalho por segundo e a CPU processa 8000 ciclos por segundo.

Na linguagem da teoria de filas nunca falamos em “ciclo”. Dizemos:

λ A taxa média de chegada é 3 tarefas por segundo.

μ A taxa média de atendimento da CPU é 4 tarefas por segundo.


Erro clássico no Trabalho 1

$E[S] = 1 \text{ u.t.} \Rightarrow \mu = 1/E[S] = 1$. Se o tempo de serviço fosse 0,05 u.t., então $\mu = 20$ e não 0,05.

Teoria de Filas

Notação de Kendall: $A/S/c$

Notação abreviada para descrever uma fila:



- M = *Markoviano* (exponencial / sem memória)
- D = determinístico G = geral E_k = Erlang- k
- Ordem de serviço: salvo indicação em contrário, **FCFS** (*First Come, First Served*).

No Trabalho 1

Cada servidor tem **1 thread** e **fila própria**: cada servidor é uma **M/M/1**.

Cuidado: o sistema **não** é uma M/M/3 — são *três filas separadas*, não uma fila compartilhada.

Teoria de Filas

Métricas de desempenho

Tempo de espera em fila, T_Q

Tempo que a tarefa passa *na fila*, sem ser atendida.

Tempo de resposta (tempo no sistema), R

$$R = T_{\text{partida}} - T_{\text{chegada}} = T_Q + S$$

Interessam $E[R]$, $\text{Var}(R)$ e a cauda $\mathbf{P}(R > t)$.

Número de tarefas

N = no sistema (na fila *mais* em atendimento); N_Q = somente na fila.

Métricas exigidas no Trabalho 1

X (vazão), $E[R]$, $E[N]$ e U_i (utilização de cada servidor).

Teoria de Filas

Vazão (*throughput*) e utilização

Definition (Vazão)

$$X = \lim_{t \rightarrow \infty} \frac{C(t)}{t},$$

onde $C(t)$ é o número de tarefas *concluídas* até o tempo t .

A vazão satura na capacidade do sistema


$$X = \min(\lambda, \text{capacidade}) \implies X = \min(\lambda, 3\mu) \text{ no Trabalho 1}$$

Utilização

U = fração do tempo em que o servidor está ocupado. Para um servidor que recebe taxa λ_i : $U = \lambda_i/\mu$ (se < 1).

Teoria de Filas

Little's Law (sistema estável)



Lei de Little

$$N = X \cdot R$$

N = número médio de tarefas no sistema, X = vazão média, R = tempo médio de resposta.

Vale para qualquer disciplina de fila e qualquer distribuição, desde que o sistema seja estável.

Teoria de Filas

Lei de Little — exemplo

Exemplo

Suponha um serviço web complexo como os do Facebook, Google, etc. Uma requisição demora, em média, 100 ms e o sistema serve, em média, 10 000 requisições por segundo. Quantas requisições estão pendentes, em média, no sistema?

Teoria de Filas

Lei de Little — exemplo

Exemplo

Suponha um serviço web complexo como os do Facebook, Google, etc. Uma requisição demora, em média, 100 ms e o sistema serve, em média, 10 000 requisições por segundo. Quantas requisições estão pendentes, em média, no sistema?

$$N = X \cdot R = 10000 \frac{\text{req}}{s} \cdot 0.1 s = 1000 \text{ requisições}$$

Uso no Trabalho 1 [T1: item e]

A Lei de Little é a **checagem de sanidade mais barata** da sua simulação: meça N , X e R de forma independente e verifique se $N = X \cdot R$. Se não bater, o bug está na sua instrumentação — não no modelo.


A distribuição Exponencial

O tijolo básico de tudo que vem a seguir

Definition (Variável aleatória exponencial)

Uma v.a. contínua $X \geq 0$ tem distribuição **Exponencial** de parâmetro (taxa) $\lambda > 0$ — escreve-se $X \sim \text{Exp}(\lambda)$ — se

$$f_X(x) = \lambda e^{-\lambda x} \ (x \geq 0), F_X(x) = 1 - e^{-\lambda x}, P\{X > x\} = e^{-\lambda x}.$$



Momentos

$$E[X] = \frac{1}{\lambda}, \quad \text{Var}(X) = \frac{1}{\lambda^2}, \quad C^2 = \frac{\text{Var}(X)}{E[X]^2} = 1$$

C^2 é a régua de variabilidade: determinístico $C^2 = 0$; exponencial $C^2 = 1$.

No Trabalho 1

Duas exponenciais: $I \sim \text{Exp}(\lambda)$ entre chegadas e $S \sim \text{Exp}(\mu)$ de serviço, com $E[I] = 1/\lambda$ e $E[S] = 1/\mu$.

Processo de Poisson

Definição

Seja $A(t)$ o **número de chegadas** em $[0, t]$ (um *processo de contagem*).

Definition (Processo de Poisson de taxa λ)

$\{A(t), t \geq 0\}$ é um processo de Poisson de taxa $\lambda > 0$ se:

- 1 $A(0) = 0$;
- 2 **incrementos independentes**: os números de chegadas em intervalos *disjuntos* são independentes;
- 3 **incrementos estacionários**: a distribuição de $A(t + s) - A(s)$ depende apenas do comprimento t , não de s ;
- 4 o número de chegadas em qualquer intervalo de comprimento t é **Poisson** de média λt :

$$P\{A(t + s) - A(s) = n\} = \frac{e^{-\lambda t} (\lambda t)^n}{n!}, \quad n = 0, 1, 2, \dots$$

Consequência imediata

$E[A(t)] = \text{Var}(A(t)) = \lambda t$: λ é mesmo a **taxa média de chegadas** por unidade de tempo.


Processo de Poisson

Caracterização equivalente: tempos entre chegadas

Teorema (equivalência)

$\{A(t)\}$ é um processo de Poisson de taxa $\lambda \iff$ os tempos entre chegadas $I_1, I_2, I_3, \dots$ são **i.i.d.** com distribuição **Exponencial**(λ):

$$P\{I > t\} = e^{-\lambda t}, \quad E[I] = 1/\lambda.$$



É esta a versão que você vai implementar

Para gerar chegadas de Poisson na simulação basta sortear $I \sim \text{Exp}(\lambda)$ e acumular: `t += random.expovariate(lambda_)`.

Processo de Poisson

Por que “M” de Markoviano

Propriedade da falta de memória (*memorylessness*)

$$P\{I > s + t \mid I > s\} = P\{I > t\}$$

“O tempo que já esperei não me diz nada sobre quanto ainda falta.” É esta propriedade que torna o estado do sistema uma **cadeia de Markov** — basta saber *quantas* tarefas há, não há quanto tempo cada uma está lá.

Consequência prática

Toda a análise que faremos a seguir só é simples *por causa* disso. Com chegadas ou serviços não exponenciais (p. ex. Pareto), o modelo fica bem mais difícil.

Decomposição (*splitting*) de um processo de Poisson

[T1: item a] — o teorema que justifica todo o resto

Teorema

Seja $\{A(t)\}$ um processo de Poisson de taxa λ . Se cada chegada for encaminhada, **de forma independente**, ao servidor i com probabilidade p_i (com $\sum_i p_i = 1$), então os processos resultantes $\{A_i(t)\}$ são processos de Poisson **independentes** de taxas $\lambda_i = p_i \lambda$.

Esboço da prova

$$P\{A_i(t) = n_i, \forall i\} = \sum_n \frac{e^{-\lambda t} (\lambda t)^n}{n!} \binom{n}{n_1 n_2 n_3} \prod_i p_i^{n_i} = \prod_i \frac{e^{-p_i \lambda t} (p_i \lambda t)^{n_i}}{n_i!}$$

A distribuição conjunta **fatora** $\Rightarrow$ Poisson e independentes.

No Trabalho 1: política aleatória com $p_i = 1/3$.

$$\lambda_i = \lambda/3$$

em cada servidor, e os 3 são independentes.

Redes de Filas

[T1: item a] — por que podemos analisar um servidor de cada vez

- Sistemas reais raramente são uma fila isolada: formam **redes de filas**.
- Uma **Rede de Jackson** é o modelo padrão: chegadas externas de Poisson, e ao terminar no nó i a requisição vai para o nó j com probabilidade P_{ij} , ou deixa a rede.

Equações de tráfego

$$\lambda_i = \gamma_i + \sum_j \lambda_j P_{ji}$$

No Trabalho 1: nó 0 = balanceador ($\gamma_0 = \lambda$), $P_{0i} = 1/3$, sem realimentação $\Rightarrow \lambda_i = \lambda/3$ (rede **acíclica**).

Teorema de Jackson — solução em forma-produto

$P(n_1, n_2, n_3) = P_1(n_1) \times P_2(n_2) \times P_3(n_3)$. Assim, cada nó se comporta como uma fila independente alimentada por λ_i . É isto que autoriza resolver uma M/M/1 e multiplicar por 3.

A fila M/M/1

[T1: item b] — distribuição estacionária

Cadeia de nascimento-e-morte: sobe à taxa λ_i , desce à taxa μ . Balanço entre estados vizinhos:

$$\lambda_i p_k = \mu p_{k+1} \implies p_{k+1} = \rho p_k$$


com $\rho = \lambda_i/\mu$. Normalizando $\sum_k p_k = 1$:

$$p_k = (1 - \rho) \rho^k$$

Leitura

$p_0 = 1 - \rho$ é a fração do tempo em que o servidor está **ocioso**; portanto, a utilização é

$$U = 1 - p_0 = \rho \lambda_i / \mu. \quad (1)$$



A fila M/M/1

[T1: item b] — o formulário completo

Quantidade	Expressão
Utilização	$U = \rho = \lambda_i / \mu$
Servidor ocioso	$p_0 = 1 - \rho$
Tarefas no sistema	$E[N_i] = \rho / (1 - \rho)$
Tarefas na fila	$E[N_Q] = \rho^2 / (1 - \rho)$
Espera em fila	$E[T_Q] = \rho / (\mu - \lambda_i)$
Tempo de resposta	$E[R] = 1 / (\mu - \lambda_i)$
Estabilidade	$\rho < 1 \iff \lambda_i < \mu$

Confira: $E[N_i] = \lambda_i E[R]$ — a Lei de Little vale, como tem que valer.

Aplicando ao Trabalho 1

[T1: item a,b] — do balanceador ao número

Três passos

- 1 **Decomposição:** $\lambda_i = \lambda/3$ em cada servidor (item a).
- 2 Cada servidor é uma M/M/1 com $\rho = \frac{\lambda_i}{\mu} = \frac{\lambda}{3\mu}$.
- 3 Substituir no formulário:

$$U_i = \frac{\lambda}{3\mu}, \quad E[N] = 3 \cdot \frac{\rho}{1 - \rho}, \quad \boxed{E[R] = \frac{1}{\mu - \lambda/3}}$$

Estabilidade e vazão

$$\rho < 1 \iff \lambda < 3\mu = 3 \text{ req/u.t.}, \quad X = \min(\lambda, 3)$$

Aplicando ao Trabalho 1

[T1: item b] — exemplo resolvido e tabela a completar

Exemplo resolvido: $\lambda = 2,4$, $\mu = 1$

$$\lambda_i = 2,4/3 = 0,8$$

$$E[R] = \frac{1}{1 - 0,8} = 5,00 \text{ u.t.}$$

$$\rho = 0,8/1 = 0,8 = U_i$$

$$E[N] = 3 \cdot \frac{0,8}{0,2} = 12,0 \text{ req}$$

λ	ρ	λ_i	U_i	$E[N]$	$E[R]$
0,6	0,2	0,2	?	?	?
1,2	0,4	0,4	?	?	?
1,8	0,6	0,6	?	?	?
2,4	0,8	0,8	0,8	12,0	5,00
2,7	0,9	0,9	?	?	?

Complete esta tabela no relatório: é exatamente o que o item (b) pede.

Note como $E[R]$ **explode** quando $\rho \rightarrow 1$: dobrar a carga de 0,4 para 0,8 triplica o tempo de resposta.

Conservação de trabalho

[T1: item c] — o que a política *não* muda

Vazão

Em regime estável nenhuma requisição é descartada: tudo que entra acaba saindo. Logo

$$X = \lambda \quad \text{para qualquer política.}$$

Utilização

O trabalho que chega por unidade de tempo é $\lambda E[S] = \lambda/\mu$, e tem de ser absorvido pelos 3 servidores:

$$\bar{U} = \frac{\lambda}{3\mu} = \rho \quad \text{também independente da política.}$$

Por simetria, $U_i = \rho$ em cada servidor nas três políticas.

Conclusão

A política afeta **apenas** o tempo de resposta. Vazões ou utilizações diferentes entre as políticas na sua simulação = bug.

Por que as políticas diferem

[T1: item d] — variabilidade e informação de estado

Escolha aleatória — *tem* modelo fechado

O sorteio i.i.d. preserva a aleatoriedade: cada servidor vê uma corrente de Poisson pura (coeficiente de variação quadrático $C_a^2 = 1$). É o **pior** caso: por azar, um servidor pode receber várias requisições seguidas enquanto outro fica ocioso.

Round-Robin — só simulação

A divisão cíclica 1-em-3 é **determinística**: o intervalo entre chegadas consecutivas num servidor é a **soma de 3 exponenciais** = Erlang-3, com $C_a^2 = 1/3$. **Mesma taxa média, menos variabilidade $\Rightarrow$ menos espera.**

Fila mais curta — só simulação


Usa **informação de estado** na hora de decidir: evita enfileirar atrás de um servidor ocupado quando há outro livre. É a melhor das três, e a vantagem cresce com a carga.

Uma máquina rápida ou muitas lentas?

A intuição por trás da “fila mais curta”

A pergunta

Uma CPU rápida de velocidade s , ou n CPUs lentas de velocidade s/n cada?



Resposta: depende da variabilidade e da carga

Com alta variabilidade dos tamanhos, preferimos muitos servidores lentos (tarefas curtas não ficam presas atrás de longas); com carga baixa, uma máquina rápida é melhor. *É a mesma ideia da “fila mais curta”: ela aproxima um recurso único e compartilhado, em vez de 3 recursos isolados.*

Sistemas instáveis

[T1: item f] — quando as fórmulas param de valer

- O que acontece quando $\lambda \geq 3\mu$?
- O sistema **perde o regime estacionário**: $\rho \geq 1$ e $\sum_k p_k$ **diverge**.
- O tamanho da fila e o tempo de espera crescem **indefinidamente**.
- Todas as fórmulas dos slides anteriores dão ∞ — inclusive a Lei de Little, que **pressupõe estabilidade**.

No Trabalho 1

O experimento com $\lambda = 3,3 > 3\mu$ é justamente este caso. Não tente aplicar M/M/1 nem Little nele.

Regime transiente

[T1: item f] — analisando um sistema instável

Aproximação fluida determinística

O sistema recebe λ e drena a 3μ ; o excedente se acumula linearmente:

$$\boxed{N(t) \approx N(0) + (\lambda - 3\mu) t} \quad R(t) \approx \frac{N(t)}{3\mu}$$

Com $\lambda = 3,3$ e $\mu = 1$

$N(t) \approx 0,3t$ e $R(t) \approx 0,1t$: ao final de 5000 u.t. haveria ≈ 1500 requisições pendentes e latência de ≈ 500 u.t..

Implicação

A fila esgotará qualquer buffer finito. As únicas saídas são **controle de admissão** (descarte deliberado) ou **scaling out** (mais capacidade).

Buffer finito: M/M/1/K

Ponto extra do Trabalho 1

Se a fila de cada servidor for limitada a K requisições, as excedentes são **descartadas**:

$$p_k = \frac{(1 - \rho)\rho^k}{1 - \rho^{K+1}}, \quad 0 \leq k \leq K \quad P_{\text{perda}} = p_K$$

Vazão efetiva

$$\lambda^{\text{ef}} = \lambda (1 - P_{\text{perda}}), \quad E[R] = E[N]/\lambda^{\text{ef}}$$

Atenção: com perdas, a Lei de Little usa a taxa **efetiva**, não λ .

Observação

Com buffer finito o sistema **nunca** é instável — ele simplesmente descarta. O preço da estabilidade é a perda.

Como medir na simulação

O que separa um resultado de um número qualquer

Regime transiente inicial (*warm-up*)

A simulação começa vazia, o que **subestima** $E[R]$. Descarte as primeiras unidades de tempo antes de coletar estatísticas. **No Trabalho 1: $T = 5000$ u.t., descartar 500 u.t..**

Réplicas e intervalo de confiança

Uma execução é uma amostra, não um resultado. Rode $n = 10$ réplicas com sementes diferentes e reporte

$$\bar{x} \pm t_{n-1; 0,975} s/\sqrt{n}, \quad t_{9; 0,975} = 2,262$$

Medindo $E[N]$ corretamente

$E[N]$ é uma média **temporal**: a área sob a curva $N(t)$ dividida pela duração — *não* a média sobre as chegadas. Em carga alta as duas diferem visivelmente.

Checklist

O que desta aula você usa em cada item do Trabalho 1

Item	O que o enunciado pede	Slide
(a)	Decomposição de Poisson $\Rightarrow \lambda_i = \lambda/3$, independência	<i>Splitting</i> / Jackson
(b)	Cada servidor é M/M/1; U_i , $E[N]$, $E[T_Q]$, $E[R]$; estabilidade; X	Formulário M/M/1
(c)	X e U_i são iguais nas três políticas	Conservação de trabalho
(d)	Comparar $E[R]$ simulado das 3 políticas com $\frac{1}{\mu - \lambda/3}$	Variabilidade
(e)	Verificar $N = X \cdot R$ na simulação	Lei de Little
(f)	$\lambda = 3,3$: instabilidade e $N(t) \approx (\lambda - 3\mu)t$	Regime transiente

Se você precisar de algo além de uma M/M/1...

... provavelmente errou o modelo. Todo o item (b) sai de $p_k = (1 - \rho)\rho^k$ com $\rho = \lambda/3\mu$.

Escalabilidade/Técnicas

- Escalabilidade de tamanho em muitos casos é a menos problemática
 - ▶ Simples aumento da capacidade de uma máquina resolve a questão, ao menos temporariamente
- Escalabilidade geográfica mais difícil, depende da natureza.
 - ▶ Combinar técnicas de distribuição, replicação e cache com diferentes formas de consistência é suficiente em diversos casos
- Escalabilidade administrativa é a mais difícil porque envolve não só problemas técnicos (políticas de organizações e colaborações humanas)
 - ▶ Solução parcial: P2P, onde usuários finais tem o controle administrativo. Não resolve todos os casos!

Muito Obrigado!

Carlos A. Astudillo

castudillo@unicamp.br



UNICAMP

